

## 1. 实验 1: Zero-Shot DeepSeek 评分

本研究的第一项实验采用 Zero-Shot 方式利用 DeepSeek-v3 模型对经济政策不确定性指数 (Economic Policy Uncertainty, EPU) 进行评估。在此实验中, 我们未进行任何额外的模型训练或示例输入, 而是直接使用 DeepSeek-v3 的内置知识对新闻文本进行评分。具体而言, 本实验包括以下几个步骤:

第一步, 数据准备。我们以 2024 年人民日报每日发布的财经新闻文本为分析对象。具体地, 通过网络爬虫技术自动获取人民日报官网每日发布的财经版块所有新闻全文, 确保获取完整的新闻文本, 并记录其具体发布日期, 以便构建日度的 EPU 数据。

第二步, 文本预处理。将抓取到的新闻文本进行初步清洗, 去除广告、图片说明等无关文本, 并将清洗后的每条新闻文本分别保存为独立的分析单元, 以供模型处理。

第三步, API 调用与评分。逐条将新闻原文通过 DeepSeek-v3 的官方 API 接口进行提交, 调用模型的内置 Zero-Shot 推理功能, 模型基于自身预训练阶段获得的知识, 直接输出针对每条新闻的 EPU 评分。每条新闻的评分介于 0 到 10 之间, 其中 0 分表示新闻文本所反映的经济政策环境完全确定, 几乎无任何不确定性; 10 分则表示新闻所体现的经济政策环境高度不确定, 存在明显的经济风险和政策波动。

第四步, 构建日度 EPU 指数。在获得单条新闻 EPU 评分后, 将每日所有新闻文本的 EPU 评分求取算术平均值, 形成每日的日度 EPU 数据, 用于进一步分析。

与传统基于关键词频率计算 EPU 指数的方法不同, Zero-Shot DeepSeek-v3 模型不依赖于预设的关键词或情感词典, 而是通过内置的预训练知识和语义理解能力直接对文本内容进行语义感知和评分。这种方法的优势在于无需提前构建和维护关键词库, 且模型能够自主捕捉文本中更加细微的语义变化, 更全面地反映新闻所传达的政策不确定性程度。

然而, Zero-Shot 方式的局限性也较为明显。由于缺乏具体评分标准或示例指引, 模型在处理某些特定新闻文本时可能会表现出评分不稳定, 甚至产生较大的方差。这种不稳定性主要表现为个别新闻措辞差异对评分结果造成较大的影响, 从而可能降低 EPU 指数的稳定性和解释力。因此, 在后续实验中, 我们将进一步探讨通过 Few-Shot 学习和微调方式优化 DeepSeek 模型评分稳定性的可能性。

## 2. 实验 2: Few-Shot DeepSeek 评分

与实验 1 的 Zero-Shot 方法相比, 本实验在 DeepSeek-v3 模型评分过程中引入了 Few-Shot 学习方式。Few-Shot 方法的核心思想是向模型提供少量典型示例, 以帮助模型更好地理解评分任务的具体标准, 从而提高评分的稳定性和一致性。具体而言, 本实验包括以下几个步骤:

第一步, 示例数据选取。我们首先人工挑选了一批具有代表性的新闻样本作为 Few-Shot 示例数据。这些示例涵盖了经济政策不确定性的不同强度等级(低、中、高不确定性), 例如“明确利好政策出台”(低不确定性)、“政策变动方向未明”(中等不确定性)、“重大政策调整传言但未确定”(高不确定性)等典型情境, 每个示例都明确标注了相应的评分值及评分理由。

第二步, 构建 Few-Shot prompt 模板。将上述挑选的示例数据整理为标准化的 prompt 模板, 即在 prompt 中明确给出示例新闻文本、对应评分以及详细评分理由, 使 DeepSeek-v3 能够快速、清晰地理解评分任务的标准与规则。

第三步, 调用模型 API 进行 Few-Shot 评分。每次评分时, 我们都将事先构建的 Few-Shot prompt 模板连同待测新闻文本一并输入到 DeepSeek-v3 模型的 API 中, 模型根据 Few-Shot 示例进行类比推理, 自主输出每条新闻的经济政策不确定性(EPU)评分, 评分范围为 0 至 10。

第四步, 构建日度和月度 EPU 指数。在模型完成逐条新闻评分后, 将每日所有新闻的评分取算术平均值, 生成日度 EPU 指数; 进一步, 将日度 EPU 指数计算月度算术平均值, 构建月度 EPU 指数。

实验结果表明, 相较于实验 1 的 Zero-Shot 方法, Few-Shot 学习显著提升了 DeepSeek-v3 评分的准确性和稳定性。通过给出评分标准示例, 模型能够有效避免因单个新闻表述不规范或语义复杂而导致评分波动较大的问题。这一改进在实验数据分析中体现为更加稳健的日度与月度 EPU 指数, 且与市场波动率的相关性更高。具体而言, 通过 Few-Shot 方法生成的 EPU 指数与市场波动的滞后一期和二期相关系数均明显高于 Zero-Shot 方法, 这说明 Few-Shot 学习在提高模型的稳定性和减少评分偏差方面发挥了关键作用。

因此, 本实验验证了通过 Few-Shot 学习增强 DeepSeek-v3 模型在经济政策不确定性测度任务中的表现是可行且有效的, 也为后续实验中进一步结合其他技术(如关键词抽取和模型微调)提供了坚实基础。

## 3. 实验 3: TF-IDF 关键词 + Few-Shot 评分

在实验 2 中，我们发现 Few-Shot 学习方式能够有效提高 DeepSeek-v3 模型对经济政策不确定性（EPU）评分的稳定性和准确性。然而，单纯依靠 Few-Shot 学习仍然存在一定局限性，例如模型可能难以有效识别新闻文本中的关键术语或主题，进而影响评分的精确度。因此，本实验在 Few-Shot 评分的基础上进一步引入了 TF-IDF 关键词提取技术，以更精准地捕捉新闻文本中的核心信息，进而优化 DeepSeek-v3 的评分能力。具体而言，本实验包括以下几个步骤：

第一步，新闻文本预处理。我们首先将 2024 年人民日报日度财经新闻文本进行预处理，具体包括去除标点符号、停用词和无意义的字符，以提高关键词提取的质量。

第二步，TF-IDF 关键词提取。本实验使用经典的 TF-IDF 算法对新闻文本进行处理。具体而言，我们基于整个 2024 年的人民日报财经新闻语料库，计算每篇新闻文本中各词汇的 TF-IDF 值，并针对每条新闻，提取 TF-IDF 值排名前 20 的关键词。这些关键词是每篇新闻中最具代表性的术语，具有较高的文本区分能力与主题概括性。

第三步，构建关键词增强的 Few-Shot prompt 模板。我们将每条新闻提取的 20 个关键词与新闻原文一同整合为标准化的 prompt 输入模板，并与实验 2 中的 Few-Shot 评分示例一同提供给 DeepSeek-v3 模型。通过这种方式，模型不仅能够根据 Few-Shot 示例的评分逻辑进行类比推理，同时还能更加明确地关注并利用新闻文本中具有显著政策含义的关键词信息。

第四步，调用 DeepSeek-v3 模型 API 进行评分。基于构建好的关键词增强 Few-Shot prompt 模板，我们逐条调用 DeepSeek-v3 API，对每篇新闻进行评分，模型在评分过程中重点关注由 TF-IDF 算法提取的核心关键词，从而有效减少冗余或次要信息对评分造成的干扰。

第五步，构建日度与月度 EPU 指数。在模型输出所有新闻评分后，我们同样采取实验 1 和实验 2 中的方法，通过求取每日评分的算术平均值得到日度 EPU 指数，并进一步计算月度平均值，构建月度 EPU 指数。。

实验结果显示，结合 TF-IDF 关键词和 Few-Shot 评分方法显著改善了模型的表现。通过聚焦于新闻文本中的核心关键词，DeepSeek-v3 模型更有效地捕捉了文本中的政策不确定性信号，并减少了评分过程中非关键内容对评分结果的干扰。具体来看，与单纯的 Few-Shot 学习相比，本实验方法得到的 EPU 指数与市场波动率的相关性进一步提升，特别是在滞后一期与滞后二期的相关系数均有所增加。

这说明 TF-IDF 关键词提取在帮助模型精确识别文本关键信息方面起到了关键作用。

#### 4. 实验 4: Transformer 训练 + 机器学习预测

与前述基于直接评分的方法相比,本实验采用了一种更为系统的文本分析与评分预测框架。首先,我们利用人工标注的 EPU 新闻数据(1425 条已标记了经济政策不确定性标签的新闻文本)作为训练数据,使用 Transformer 类模型(如 BERT)进行训练。BERT 模型凭借其强大的文本特征提取能力和上下文感知能力,能够高效地学习文本中与经济政策不确定性相关的语义特征和表达模式。具体而言,本实验包括以下几个步骤:

第一步,数据准备与预处理。我们选取了 1425 条已由研究人员人工标注了经济政策不确定性评分的人民日报财经新闻文本作为训练数据。这些评分的范围从 0 至 100,分别代表新闻所反映的经济政策不确定性程度。数据预处理的内容包括去除文本中无意义的符号、数字和停用词,并进行中文文本分词与词嵌入处理,以便于 Transformer 模型学习。

第二步,构建 Transformer 分类任务。我们将 EPU 评分预测任务转化为标准的回归任务,即使用 Transformer(例如 BERT)模型对新闻文本进行回归预测,目标输出为每条新闻对应的 EPU 评分值(0-10 之间的连续数值)。模型的输入为预处理和分词后的新闻文本特征,输出为对应的 EPU 评分预测结果。

第三步,划分数据集与模型训练。我们采用经典的 8:1:1 比例随机划分,将 1425 条标注文本分为训练集、验证集和测试集。随后使用训练集对 Transformer 模型进行训练,并在验证集上进行参数调优。训练目标为最小化模型预测评分与人工标注评分之间的均方误差(MSE),以优化模型对经济政策不确定性的理解与预测能力。

第四步,模型评估与性能验证。训练完成后,我们在测试集上进行模型性能评估,分别计算均方误差(MSE)、平均绝对误差(MAE)和决定系数( $R^2$ )等指标来评估 Transformer 模型对新闻文本的 EPU 评分预测性能。实验结果显示,与 Zero-Shot 和 Few-Shot 方法相比,本方法在评分的一致性、稳定性和预测精确度方面表现显著提升。

第五步,利用训练好的模型进行新数据预测。最后,我们将训练完成的 Transformer 模型应用到未标注的 2024 年人民日报日度财经新闻中,自动预测每条新闻的经济政策不确定性评分。根据预测出的日度评分结果,我们进一步计算

每日的 EPU 指数平均值，并构建月度 EPU 指数，为后续市场波动与政策分析提供可靠的数据基础。

与之前的零样本（Zero-Shot）和少样本（Few-Shot）学习方法相比，该方法能够更充分地利用历史标注数据，训练模型更深入地理解和捕捉新闻文本中的政策不确定性特征。实验证明，通过这种方式训练的 Transformer 模型在评分的一致性、稳定性及准确性方面均有显著提高，为经济政策不确定性指数的精确度提供了坚实的技术支持。

## 5. 实验 5: LoRA 微调 DeepSeek-v1

传统的预训练模型在处理特定任务时，由于未针对具体任务数据进行针对性优化，常常表现出泛化能力有限、准确性不足的缺点。为进一步提高 DeepSeek 模型在经济政策不确定性（EPU）评分任务中的准确性，本研究采用 LoRA

（Low-Rank Adaptation）方法对 DeepSeek-v1 进行微调。LoRA 是一种参数高效的微调技术，通过低秩矩阵的方式更新部分参数，而非全量参数，能够在不明显增加计算资源的情况下显著提升模型的性能。

第一步，数据准备与文本预处理。我们选取前述实验所使用的 1425 条人工标注的人民日报财经新闻文本作为训练样本，每条新闻已人工赋予了明确的经济政策不确定性评分（0-100）。对这些文本的预处理步骤包括中文分词、去除停用词、文本清洗与规范化处理，确保输入模型的数据格式统一且便于模型有效学习文本特征。

第二步，构建微调数据集。经过预处理的文本数据与对应的人工标注评分一起构成了微调数据集。数据集按照经典的 8:1:1 比例划分为训练集、验证集和测试集，以用于 LoRA 微调、模型参数调优和性能评估。

第三步，实施 LoRA 微调。采用 LoRA 框架在 DeepSeek-v1 预训练模型基础上进行微调。具体而言，冻结 DeepSeek-v1 模型的大部分预训练参数，仅在模型的注意力层中引入少量可训练的低秩矩阵，通过这些低秩矩阵来高效地调整模型以适应特定的 EPU 评分任务。LoRA 微调的优势在于，它只需要更新少量参数，极大地降低了计算资源需求，同时保持甚至提高了模型的表现。

第四步，模型性能评估与参数优化。在微调过程中，我们利用验证集对模型的表现进行监控，并通过调整学习率、秩大小（rank）等关键超参数，以优化微调后的模型性能。微调目标是使模型预测的评分与人工标注评分的均方误差

(MSE) 达到最小化。微调结束后, 利用测试集评估微调模型的表现, 记录并分析各项指标 (如 MSE、MAE 和  $R^2$ )。

第五步, 使用微调模型预测新数据。训练与验证完成后, 我们将经过 LoRA 微调后的 DeepSeek-v1 模型用于 2024 年人民日报的每日财经新闻文本, 以自动预测其经济政策不确定性评分。基于预测结果, 进一步计算每日新闻的评分均值, 进而构建日度及月度 EPU 指数, 为后续市场分析提供高质量的数据支持。

实验结果显示, 相比于未经微调的 DeepSeek 模型, 经过 LoRA 微调后的 DeepSeek-v1 在评分精度、稳定性及对新闻文本的语义理解能力上均有显著提升。通过 LoRA 微调, DeepSeek 模型更加适应特定任务场景, 从而提高了构建经济政策不确定性指数的准确性和可靠性。

## (二) 更多改进

### 1. 实验 6: 基于主题建模 (TopicGPT) 的 EPU 评分预测改进

虽然基于 LoRA 微调的 DeepSeek 模型 (实验 5) 已显著提高了 EPU 评分的准确性, 但由于经济政策不确定性往往涉及多种复杂主题, 模型在理解和区分不同政策主题方面仍存在一定局限。为进一步提升模型对新闻文本中经济政策不确定性的理解能力和评分准确性, 本研究在实验 5 的基础上, 引入了主题建模 (Topic Modeling) 方法, 尤其是最近提出的 TopicGPT 技术, 以更有效地捕捉和利用新闻文本中的潜在政策主题信息, 从而优化 EPU 预测结果。

本实验的具体步骤如下:

第一步: 数据准备与文本清洗。选取与实验 5 相同的 1425 条已标注 EPU 评分的人民日报新闻文本, 作为主题建模的输入语料。在此基础上进行统一的文本预处理, 包括中文分词、去停用词、去除低频词和噪声字符, 以确保模型能够专注于核心政策内容。

第二步: 应用 TopicGPT 进行主题提取。将处理后的文本输入 TopicGPT 模型, 对每条新闻文本进行主题分布建模。模型自动推理出该新闻可能涉及的 1~3 个主要政策主题, 每个主题由若干关键词 (如“货币宽松”、“财政支出”、“出口退税”等) 表示, 能够有效刻画该新闻所传递的政策焦点。

第三步: 生成主题嵌入并融合入文本表示。基于 TopicGPT 的主题输出, 我们将每条新闻的主题信息编码为向量表示 (即 Topic Embedding), 并与原始文本的语义表示一同作为输入, 送入已通过 LoRA 微调的 DeepSeek-v1 模型中。融合

后的输入不仅包含原始文本信息，还引入了高层次的主题结构，提升模型对政策不确定性的捕捉能力。

第四步：进行 EPU 评分预测与结果生成。模型在训练集上完成主题增强后的微调后，使用融合主题信息的新模型对 2024 年人民日报日度新闻进行逐条评分，并基于每日评分均值构建新的日度和月度 EPU 指数。

第五步：对比分析与评估效果。将融合 TopicGPT 的模型评分结果与仅基于 LoRA 微调的模型结果进行横向对比，发现主题增强模型在多个方面取得了改进：评分更贴近人工标签、日度 EPU 曲线更加平滑稳定、与市场波动的滞后相关性进一步增强。这表明，引入主题建模有助于提升模型理解文本深层含义的能力，并在量化经济政策不确定性时展现出更强的解释力与预测能力。

## 2. 实验 7: RAG 检索增强

尽管主题建模能够有效地识别新闻文本中的潜在主题，但模型仍可能由于训练数据或预训练知识库的局限，无法完整捕捉特定新闻中的背景信息和外部知识。这种局限性可能会导致模型在进行经济政策不确定性（EPU）评分时出现信息遗漏或误判的问题。为解决这一挑战，本实验在实验 6 主题建模的基础上进一步引入了检索增强生成（Retrieval-Augmented Generation, RAG）方法。

本实验的具体步骤如下：

第一步：构建外部经济政策知识库。我们基于 2020 年以来的政策文件、经济研究报告、官方统计公报以及历史新闻稿件等多源异构数据，构建了一个涵盖宏观政策、财政与货币政策事件、市场监管措施及全球主要经济事件的文献型数据库。该数据库总计收录超 10 万篇文献，并以向量形式嵌入至 FAISS 检索系统中，支持基于语义的相似性检索。

第二步：新闻文本向量化与相关文献检索。在对待评分的 2024 年人民日报新闻进行预处理（包括分词、去除噪声、统一编码）后，使用 BERT 类模型对文本进行向量化表示。随后，系统自动以该新闻嵌入向量为查询条件，在外部经济政策知识库中检索与之语义最相关的若干篇背景材料（通常为前 3~5 篇），确保所引文献能覆盖与新闻主旨相关的历史背景、政策发展脉络及先前影响分析。

第三步：构建 RAG 输入并增强 DeepSeek 模型。将原始新闻文本与上述检索到的相关背景文献拼接组合，作为扩展输入，送入在实验 6 基础上微调后的 DeepSeek 模型。模型在接收新闻本身信息的同时，能够借助外部知识为评分提

供语境支持，尤其在处理缺乏明确线索或内容晦涩的新闻文本时，表现出更高的理解能力。

第四步：生成评分并构建 EPU 指数。在上述增强输入基础上，DeepSeek 模型输出每条新闻的 EPU 评分。我们以新闻逐条评分结果为基础，构建日度和月度 EPU 指数，并与实验 5 与实验 6 结果进行横向对比，重点评估评分稳定性、分布合理性以及与市场波动率的相关性。

第五步：效果评估与案例分析。实验结果显示，RAG 方法引入外部背景知识后，模型的评分波动性显著下降，评分结果更趋平滑和合理。在与市场波动的滞后相关性方面，RAG 增强模型构建的 EPU 指数在滞后一期与滞后二期均取得更高的相关系数。此外，针对多篇语义含混或表述模糊的新闻，我们进一步开展个案对比分析，发现 RAG 模型能够借助外部知识有效弥补原始文本信息不足所带来的评分误差。

与单纯依赖主题建模的方法相比，RAG 方法能够更好地弥补模型知识面的局限性，显著提高评分的稳定性和准确性。此外，本实验采用的检索技术还能够动态更新和扩展知识库，及时反映最新的经济政策变化和市场情况，确保模型对 EPU 的评分始终具备较高的时效性和精准度。

### 3. 实验 8：GraphRAG 图检索增强

尽管经过主题建模（实验 6）和传统 RAG 检索增强（实验 7）的方法，已经显著提高了 DeepSeek 模型对新闻文本中经济政策不确定性（EPU）的评分效果，但现有方法仍主要局限于从文本或非结构化数据中直接检索信息，这种方式在处理复杂实体关系或隐含语义结构时往往存在局限。为进一步提升模型对复杂知识和实体间关系的捕捉能力，本研究创新性地主题建模的基础上引入了基于图结构的检索增强方法（GraphRAG）。

本实验的具体步骤如下：

第一步：构建经济政策知识图谱。我们首先基于 2020 年至 2024 年间的政策公告、宏观经济新闻、金融监管文件及市场研究报告等文本资料，抽取出其中的核心实体（如“财政政策”、“美联储”、“通货膨胀”、“外汇市场”等）及其之间的语义关系（如“导致”、“调控”、“受影响于”等）。随后利用命名实体识别（NER）、依存句法分析（Dependency Parsing）等自然语言处理技术，对文本进行实体及关系抽取，并构建结构化的知识图谱。最终形成一个覆盖政策主题、宏观事件、经济部门与市场变量之间关系的大型图数据库。



第二步:图数据库的嵌入与查询优化。将构建完成的知识图谱导入基于 Neo4j 或 TigerGraph 等平台的图数据库中,并使用图嵌入(Graph Embedding)方法,如 GraphSAGE 或 Node2Vec,将节点与边转换为低维向量表示,便于与新闻文本语义向量进行融合与比对。同时,针对评分任务优化图查询算法,实现基于新闻内容的语义向量召回图中最相关的节点子图,自动定位与新闻主旨高度相关的政策路径与知识链路。

第三步:融合图谱结构与新闻语义信息。在每次进行 EPU 评分时,模型会先基于新闻语义向量,在知识图谱中检索对应的子图片段,获取与当前新闻相关的政策背景路径和实体关系网。随后,将图结构中的实体节点、边关系及其嵌入信息,与新闻文本及主题建模(TopicGPT)提取的主题向量一同输入到经过微调的 DeepSeek 模型中,形成多源融合的增强输入。

第四步:生成评分并构建指数。DeepSeek 模型在接收到图谱增强后的输入后,基于更丰富的上下文和结构化知识,对每条新闻进行 EPU 评分,生成更精细化和可解释的评分结果。我们以逐条新闻评分为基础构建日度与月度 EPU 指数,并与实验 6 和实验 7 的结果进行对比分析,重点考察评分准确性、稳定性以及与市场波动指标(如 VIX、沪深 300 波动率)的相关性。

第五步:可解释性与可视化分析。由于图谱结构具备天然的可解释性,我们在模型生成 EPU 评分的同时,保留其在图谱中所使用的推理路径、节点链路及知识片段。通过图可视化工具(如 Graphistry、D3.js),研究者可直观查看模型如何通过“财政支出→通货膨胀预期→利率政策调整”等路径推导评分,有助于后续模型评估和结果解释。

这种基于图谱增强的检索生成方式较传统方法具有以下突出优势:首先,图谱结构有助于更加精确地捕捉新闻文本中的实体关系和复杂语义结构,减少了传统检索方法中常见的信息遗漏和误判;其次,图谱检索的智能性和交互性使模型能够根据上下文和已有信息动态选择最相关的知识路径,极大地提高了信息检索的针对性和效率;最后,GraphRAG 方法的可解释性更强,模型通过节点和关系的显式表示,生成决策过程更加透明,有助于后续分析和模型结果的解读。

### (三) 基于 DeepSeek-r1 模型的改进与 COT 功能应用

#### 1. 实验 9: 加入 DeepSeek-r1 的 Chain of Thought (COT) 功能进一步优化测度

实验 6 至实验 8 分别从主题建模、RAG 检索增强以及图结构知识增强的角度对 DeepSeek 模型的预测准确性进行了优化。然而，这些实验依然存在预测过程透明性不足的问题，即模型做出决策的具体推理过程并未显式体现，这使得后续结果的可解释性和评估精度均受到限制。

为此，本研究引入 DeepSeek-r1 模型特有的 Chain of Thought (COT) 推理机制。COT 机制是一种显式的推理框架，通过强制模型逐步输出自身的推理步骤 (thinking process) 与推理理由 (reasoning)，而不仅仅输出最终的评分。具体而言，在利用 DeepSeek-r1 完成实验 6、实验 7、实验 8 的基础上，每条新闻文本均保留模型输出的详细推理过程、评分依据以及具体的评分确定性 (certainty)。

此外，实验 9 中，DeepSeek-r1 模型的输出维度不仅包括整体 EPU 评分，还进一步细化为好坏 EPU (EPU\_good、EPU\_bad) 以及高低频 EPU (EPU\_long、EPU\_short) 共五个评分维度，每个维度评分范围为 1-10。同时，模型还输出每条新闻的评分确定性 (1-100)，即模型对自身评分结果的置信度。这种细粒度的输出不仅提高了模型预测的精确度，更为后续模型微调和优化提供了清晰的依据。

本实验的实施步骤如下：

第一步：准备增强输入。在实验 6~8 的框架基础上，我们为每条人民日报财经新闻文本准备三类输入信息：一是原始新闻文本，二是由 TopicGPT 提取的主题标签或嵌入信息，三是由 RAG 或 GraphRAG 模块提供的外部补充背景资料或知识图谱路径。这些信息被统一格式整理后作为输入送入 DeepSeek-r1 模型。

第二步：构建 COT 模板与示例引导。为了引导 DeepSeek-r1 输出结构化的推理路径，我们设计了 Chain of Thought 的 Prompt 模板，包括以下结构：

- Step 1: 提取关键信息（例如“该新闻讨论的是财政刺激政策对中小企业贷款的支持”）；
- Step 2: 判断政策内容是否具备不确定性因素（如“政策细节尚未出台，企业普遍存在观望态度”）；
- Step 3: 结合历史背景或外部知识分析其可能影响路径；
- Step 4: 综合判断政策不确定性程度及其具体方向和时间维度影响；
- Step 5: 输出评分结论，并注明评分置信度。

在正式批量生成前，我们手动构造并测试了若干个具有代表性的示例，引导模型在 Zero/Few-shot 场景下形成稳态输出结构。

第三步：模型调用与输出采集。我们基于 API 方式逐条将结构化输入送入 DeepSeek-r1 模型，每次请求返回包含以下内容：新闻摘要、模型的多步推理过程 (thinking process)、模型给出的解释性判断 (reasoning)、五项评分维度：EPU、EPU\_good、EPU\_bad、EPU\_long、EPU\_short (均为 1-10)、模型评分的置信度 certainty (范围 1-10)。所有结果被保存为结构化数据 (如 JSON 格式)，并在后续环节中用于模型微调和 benchmark 对比。

第四步：数据统计与指数构建。我们基于 DeepSeek-r1 的评分结果，计算各类日度与月度 EPU 子指数，并将其与市场指标 (如波动率指数 VIX、上证综指涨跌幅) 进行相关性分析，评估 COT 机制带来的改进效果。初步结果显示，加入 COT 后的评分结果波动性更低、置信度分布更合理，且与市场实际走势之间的相关性进一步增强。

第五步：评估输出可解释性。我们进一步统计了模型输出中推理过程的连贯性与一致性，并通过人工抽查和专家评估，验证模型推理逻辑是否合理、是否存在逻辑跳跃。结果表明，引入 COT 机制后的 DeepSeek-r1 模型不仅评分更为稳定，还具备更强的可解释性，为政策研究和实务分析提供了重要的分析支撑。

综上，实验 9 通过引入 Chain of Thought 机制，不仅提高了评分的准确性与稳定性，更为后续模型微调 (实验 10) 和多轮强化学习提供了关键的结构化推理素材和高置信度样本。该机制的引入标志着本研究迈入了“可解释 EPU 指数”的新阶段。

## 2. 实验 10：基于 DeepSeek-r1 的推理过程 (thinking process)、推理理由 (reasoning) 与评分源 (source) 进行多轮微调与 benchmark 对比

尽管实验 9 引入了 DeepSeek-r1 的 COT 推理机制，提升了模型评分的可解释性与精确性，但模型的整体表现仍可能受到数据中评分确定性差异的影响。为了进一步优化模型的推理精度和稳定性，本实验利用 DeepSeek-r1 模型输出的 thinking process (推理过程)、reasoning (推理理由) 以及评分确定性 (certainty)，开展针对性更强的多轮微调。

本实验的具体步骤如下：

第一步：筛选高置信度训练样本。我们首先从实验 9 中构建的新闻评分结果中筛选出评分确定性 (certainty) 最高的前 30% 样本。该部分数据具有推理过程

完整、输出连贯性强、评分合理等特点，因此被认为是微调阶段最优质的训练数据。每条样本均包含完整的五类评分（EPU、EPU\_good、EPU\_bad、EPU\_long、EPU\_short），对应的置信度值，以及推理路径和评分依据文本。

第二步：构建微调训练集并设置训练目标。选中的高置信度样本被分为训练集（80%）和验证集（20%），并设置监督目标为：

1. 准确预测五类 EPU 评分；
2. 生成与参考推理过程语义一致的 thinking process 和 reasoning 文本；
3. 输出合理的评分置信度（certainty）值，贴近原始样本。

第三步：分阶段多轮微调模型（Student → Graduate → Expert）。为了模拟模型的推理能力逐步增强的过程，我们将微调过程划分为三轮阶段训练：

- 第一阶段（Student 模型）：使用较小批量的样本进行初步微调，帮助模型学会结构化输出推理过程、基本评分框架与判断逻辑。该阶段重在推理流程的掌握，评分指标精度次之。

- 第二阶段（Graduate 模型）：在第一阶段模型基础上加入更多训练样本，提升模型对复杂新闻文本中隐含不确定性因素的识别能力。该阶段重点优化评分的合理性和推理内容的多样性。

- 第三阶段（Expert 模型）：最终阶段使用全部高置信度样本进行微调，并调整 loss 权重强化评分准确性与推理一致性。该模型被视为最终的成熟版本，具备高可解释性与稳定性。

第四步：开展多模型 Benchmark 对比实验。为了全面评估微调后的 DeepSeek-r1 模型性能，我们设计了如下 benchmark 实验流程：

- 对比模型包括：微调后的 DeepSeek-r1（三阶段版本），以及 DeepSeek-v1、v2、v3 三个未微调模型，和 ChatGPT-4o、4.5、o1 等主流大模型；

- 每个模型均使用相同的一组 2024 年人民日报新闻数据进行评分，输出五类 EPU 指标及推理过程；

- 评估维度包括：预测准确度（与人工评分的接近度）、评分稳定性（方差分析）、推理结构连贯性（人工审阅）和 API 调用成本（token 消耗与响应时间）；

- 输出的 benchmark 表格涵盖各模型在不同任务下的精度表现、生成逻辑清晰度与性价比综合评分。

第五步：总结结果与反馈优化。实验结果表明，经过多轮微调后的 DeepSeek-r1 Expert 模型在 EPU 评分精度、推理一致性与成本控制方面均优于其他版本模型。特别是在复杂政策语境下，该模型展现出更强的理解与评分能力，能够输出高度清晰、结构完备的评分逻辑。后续将基于 benchmark 分析结果，反馈优化推理 prompt 模板与模型训练机制，以持续提升模型的实用性与可控性。

综上，实验 10 通过利用 DeepSeek-r1 在 COT 任务中的输出结构信息，构建了完整的“高置信度 → 分阶段训练 → 多模型对比”链条式优化流程，不仅进一步提升了模型的评分表现，也为高质量 EPU 指数构建提供了具备实证支撑的方法论基础。

## （五）EPU 和相关指标构建与细分方法

### 1.1 细分市场波动率指标构建方法

为更精确地捕捉经济政策不确定性与市场不同波动情形之间的联系，本研究构建了以下市场波动细分指标：

#### （1）上涨波动率（Volatility\_positive）和下跌波动率（Volatility\_negative）

采用已实现半方差（Realized Semivariance）方法，将传统市场波动率区分为上涨波动率和下跌波动率，以分别捕捉市场上涨和下跌情形下的不确定性特征，从而更精准地度量经济政策对市场不同情境下的影响。

#### （2）高频波动率（Volatility\_high\_freq）和低频波动率（Volatility\_low\_freq）

利用离散小波变换（Discrete Wavelet Transform, DWT）方法，将市场波动率分解为高频波动（短期行情波动）与低频波动（长期行情波动）两个部分，以区分经济政策不确定性在短期行情和长期行情中的不同影响特征，提升了 EPU 指数在不同投资周期下的分析有效性。

### 1.2 细分 EPU 指数的构建方法

在实验 5 对 DeepSeek-r1 模型进行 LoRA 微调的基础上，进一步设计并构建了以下 EPU 指数细分指标，以提高 EPU 指数对市场波动与政策影响方向的识别精度：

#### （1）向好不确定性指数（EPU\_good）和向坏不确定性指数（EPU\_bad）

将经济政策不确定性按照政策影响市场的方向进行分类，EPU\_good 指标反映经济政策不确定性中可能对市场形成利好效应的部分，而 EPU\_bad 指标则反映经济政策不确定性可能对市场产生负面效应的部分，以清晰区分政策不确定性的影响性质。

## （2）长期 EPU 指数（EPU\_long）和短期 EPU 指数（EPU\_short）

对经济政策不确定性进行周期区分，EPU\_long 指标测量经济政策不确定性对于长期市场行情的影响，EPU\_short 指标则捕捉经济政策不确定性在短期市场行情中的效应，以便投资者与决策者更加精确地掌握经济政策不确定性对不同时点市场波动的作用规律。